

Daily 협업일지(02/24)

[1] 오늘 날짜 / 이름 / 팀명

- 날짜: 2026.02.24
- 이름: 김슬기
- 팀명: 6팀

[2] 오늘 맡은 역할 및 구체적인 작업 내용

오늘 당신이 맡았던 역할은 무엇이었고, 어떤 작업을 수행했나요?

(예: 모델 학습 파라미터 조정, 결측치 처리, 발표자료 구성 등)

👉 답변:

PII(개인정보) 필터링 시스템 구축:

- pii_filter.py로 마스킹 로직 일원화 (주민번호, 전화번호, 이메일, IP 등)
- 문서 파싱 단계(_mask_pii)와 사용자 질문 입력 단계(Input Rail)에 마스킹 적용

RAGChain 보안 가드레일 적용:

- Input Rail: 사용자 질문 길이 제한 및 프롬프트 인젝션 패턴 스캔
- Prompt Engineering: XML 태그(<context>, <hints>) 구조로 프롬프트를 개편하여 외부 지시 무시(Meta-Prompting) 적용
- Output Rail: LLM 답변 내 민감정보(금융정보 등) 유출 시 차단 로직 구현

안정성 및 정합성 개선:

- 파싱 타임아웃(300초) 적용으로 DoS 공격 방지
- _sanitize_text 로직 강화로 깨진 문자(Mojibake) 및 의미 없는 짧은 청크 필터링

[3] 오늘 작업 완료도 체크 (하나만 체크)

진척 상황을 정량적으로 표시하고, 간단한 근거도 작성하세요.

- ☐ 0% (시작 못함)
- ☐ 25% (시작은 했지만 진척 없음)
- ☐ 50% (진행 중, 절반 이하)
- ☒ 75% (거의 완료됨)
- ☐ 100% (완료 및 점검까지 완료)

📌 간단한 근거:

(65%) 입출력 단계의 보안 장치는 마련되었으나, 외부 도구 실행 시의 네트워크 보안(SSRF)과 보안 감사 로그 시스템이 아직 연동되지 않음

[4] 오늘 협업 중 제안하거나 피드백한 내용이 있다면?

오늘 회의나 메시지에서 당신이 제안하거나 팀에 피드백한 내용은 무엇인가요?

👉 답변:

-

[5] 오늘 분석/실험 중 얻은 인사이트나 발견한 문제점은?

EDA, 모델 실험 중 유의미한 점이나 오류가 있었다면 자유롭게 작성하세요.

👉 답변:

- LLM은 문맥에 따라 시스템 프롬프트를 무시할 수 있음. 이를 방지하기 위해 사용자 입력을 XML 태그로 감싸고 "이전 지시를 무시하라"는 식의 공격을 텍스트로 취급하도록 강제하는 것이 효과적임
- hwp5txt 등 외부 라이브러리 부재 시 발생하는 바이너리 노이즈가 검색 품질을 저하시키므로 정제 로직이 중요함

[6] 일정 지연이나 협업 중 어려웠던 점이 있다면?

자기 업무 외에도 전체 일정이나 팀 내 협업에서 생긴 문제를 공유해 주세요.

👉 답변:

- 주민등록번호 정규식 패턴이 너무 단순하면 일반 숫자열도 마스킹하는 오탐(False Positive)이 발생하여, 정규식 최적화 및 검증에 노력이 필요했음

[7] 오늘 발표 준비나 커뮤니케이션에서 기여한 부분은?

슬라이드 제작, 발표 연습, 질문 정리 등 발표와 관련된 활동을 썼다면 기록하세요.

👉 답변:

-

[8] 내일 목표 / 할 일

구체적인 개인 업무나 팀 목표 기반 계획을 간단히 적어주세요.

👉 답변:

- SSRF 방지를 위한 Tool Execution Gate 구현
- 보안/감사 로그 시스템(JSON 구조화) 구축
- 통합 테스트(test_isolation_security.py) 작성 및 검증